

# Mélange de gaussiens EM

ZIDAN Loubna

2023-02-15

```
library(mvtnorm)
library(graphics)
library(ggplot2)
```

## Introduction

Expectation-Maximization (EM) est un algorithme itératif pour trouver des estimations de probabilité maximale de paramètres dans des modèles statistiques, où le modèle dépend de variables latentes non observées.

L'itération EM alterne entre l'exécution d'une étape (E), qui crée une fonction pour l'espérance de la log-vraisemblance évaluée à l'aide de l'estimation actuelle des paramètres.

Et une étape de maximisation (M), qui calcule les paramètres maximisant la log-vraisemblance attendue. vraisemblance trouvée à l'étape E.

Répéter ces étapes jusqu'à ce que la convergence soit détectée.

Au cours de ce projet, nous allons implémenter l'algorithme EM pour la distribution du mélange gaussien, en utilisant une variable latente  $Z$ .

## Plan

1-Implémenter la fonction Estep qui retourne les probabilités d'appartenance de chaque point à chaque cluster

2-Implémenter la fonction Mstep qui retourne les paramètres optimaux du modèle

3-Implémenter la fonction vraisemblance

4-Regrouper toutes ces fonctions en une seule fonction EM

La fonction EM va retourner:

-Les itérations avec les valeurs et vraisemblances correspondantes

-Le plot de vraisemblance

-Le plot des erreurs qui montre la convergence

-Les paramètres optimaux correspondants à chaque cluster: (densité( $\pi$ ), moyenne( $\mu$ ), et variance( $\sigma$ ))

-Gamma qui sont les probabilités d'appartenance de chaque point à chaque cluster

-Le cluster attribué à chaque point

-Les données colorées par cluster (plot final)

Nous allons appliquer notre modèle sur deux bases de données:

-La première est une base de données simulée multivariée à l'aide de la fonction (mvnrm) de deux dimensions avec 350 points (N).

Ses parametres seront générées en fonction de K (nombre de clusters) et degree(nombre de dimensions). Nous allons fixer k le nombre de clusters à 2.

-La deuxième base de données sera Iris, nous allons sélectionner également 2 colonnes 3 et 4, et le nombre de clusters sera égale à 2 également.

L'algorithme se repete jusqu'à n.trial fois qui est égale à N, la condition d'arrete sera :

si la proportion ((nouvelle valeur de vraisemblance moins l'ancienne valeur obtenue)divisé par l'ancienne valeur) est inferieure à un épsilon e , on sort de la boucle!

*Voici les fonctions Estep et Mstep:*

on vas donc utiliser les fonctions E step et M Step pour trouver les paramètres de la distribution du mélange gaussien et les appliquer jusqu'à la convergence.

*#Estep:*

```
Estep <- function(data,pi,mu,sigma,K){  
  result <- apply(data, 1, function(xt){  
    gamma_i <- sapply(1:K,function(k) {  
      pi[k] * dmvnorm(xt, mu[,k], sigma[,k])  
    })  
    gamma_i / sum(gamma_i) #normalization  
  })  
  gamma<- t(result)  
}
```

*#Mstep:*

```
Mstep <- function(gamma,data,K,N,degree) {  
  gamma.sum <- apply(gamma,2,sum)  
  new.pi <- gamma.sum/N;  
  new.mu <- t(t(t(data) %*% gamma) / gamma.sum);  
  new.sigma <- array(0, dim=c(degree, degree, K));  
  
  for(k in 1:K) {  
    sig <- matrix(0,degree,degree);  
    for(n in 1:N) {  
      sig <- sig + gamma[n, k] * (data[n,] %*% t(data[n,]));  
    }  
    new.sigma[,k] <- sig / gamma.sum[k] - new.mu[,k] %*% t(new.mu[,k])  
  }  
  list(new.pi, new.mu, new.sigma);  
}
```

*Calcul de la vraisemblance marginale:*

```
vraisemblance <- function(data, pi,mu,sigma,K){
```

```

loglike = matrix(0, n.trial, K)
for(k in 1:K) {
  loglike[,k] = pi[k] * dmvnorm(data, mu[,k], sigma[,k])
}
loglike = sum(log(rowSums(loglike)))

return(sum(loglike))
}

```

Ensuite, nous allons regrouper tout dans une seule fonction EM comme suivant:

*EM:*

```

EM<-function(data,K,n.trial,e){

#initialisations aléatoires des parametres :

pi <- runif(K)
pi <- runif(K)/sum(pi)

mu <- matrix(runif(K*degree), nrow=degree, ncol=K)

sigma <- array(0, dim=c(degree, degree, K))
for(k in 1:K){
  sigma[,k] <- diag(runif(degree))
}

#calculer l'error, la vraisemblance, et les parametres optimales:

count <- 0
errorlist <- rep(0,n.trial)
logliklist <- rep(0,n.trial)

for(i in 1:n.trial){
  count <- count +1
  old_loglik = vraisemblance(data,pi,mu,sigma,K)

  gamma <- Estep(data,pi,mu,sigma,K)
  result <- Mstep(gamma,data,K,N,degree)

  new.pi <- result[[1]]
  new.mu <- result[[2]]
  new.sigma <- result[[3]]

  error <-sum((new.pi-pi)^2) + sum((new.mu-mu)^2) + sum((new.sigma-sigma)^2)
  errorlist[i] <- error

  pi <- new.pi
  mu <- new.mu
  sigma <- new.sigma

  new_loglik = vraisemblance(data,pi,mu,sigma,K)
}

```

```

logliklist[i+1] = new_loglik

#critere d'arret:
critere = abs((new_loglik - old_loglik)/old_loglik)
if(critere < e) break

cat("loglike à l'étape ", i, " : ", new_loglik, '\n')
}

#Les resultats:

#Afficher le plot de vraisemblance
plot_lhood<-plot(logliklist[2:count],main='vraisemblance')

#Afficher le plot de l'erreur
plot_error<-plot(errorlist[2:count],log="y",main='error plot')

#Afficher les parametres finales:
for(k in 1:K) {
  cat('Cluster ', k, '\n')

  cat('Pi : \n')
  print(pi[k])

  cat('mu : \n')
  print(mu[k])

  cat('Sigma : \n')
  print(sigma[k])
}

#Afficher le cluster attribué à chaque point :
clustering = apply(gamma, MARGIN = 1, which.max)
plot_clustering<-plot(clustering, main='clustering plot')

clustr<-data.frame(clustering)
x<-data.frame(data[,1])
y<-data.frame(data[,2])

data_final<-data.frame(x,y,clustr)

#Afficher les données colorées par cluster:
data_plot<-ggplot(data_final) +
aes(x = data...1., y = data...2., colour = clustering) +

```

```

geom_point(shape = "circle", size = 2.45) +
scale_color_gradient(low = "#4184C8", high = "#D65A0D") +
theme_minimal() +
theme(legend.position = "none")

return(list(plot_lhood,plot_error,gamma,clustering,plot_clustering,data_plot))
}

```

*Première expérience : Appliquer EM sur des données simulées*

on utilise les paramètres ci-dessous pour générer les données

Échantillonnage d'abord N fois à partir d'une distribution multinomiale pour déterminer quel cluster génère les données, puis pour chaque résultat des échantillons de la distribution multinomiale, on utilise la distribution multi gaussienne (fonction mvnrm) pour échantillonner:

```

set.seed(1010)

K<-2 #nombre de clusters
degree <- 2 #dimensions (2D)
N <- 350 #nombre de points

pi.true <- runif(K)
pi.true <- pi.true/sum(pi.true)

mu.true <- matrix(runif(K*degree,min=-2,max=2), nrow=degree, ncol=K)

sigma.true <- array(0, dim=c(degree, degree, K))


for(k in 1:K){
  sigma.true[, ,k] <- diag(1,nrow=degree, ncol=degree)
}

data_simule <- t(apply(rmultinom(N,1,pi.true),2,function(num) {
  maxindex <- which.max(num)
  rmvnorm(1, mu.true[,maxindex], sigma.true[, ,maxindex])
})))

```


Voyons à quoi ressemblent les données:

```
plot(data_simule)
```




```
n.trial<-350
e<-1e-5
res_em = EM(data_simule,K,n.trial,e)
```

```
## loglike à l'étape 1 : -1188.474
## loglike à l'étape 2 : -1175.066
## loglike à l'étape 3 : -1171.355
## loglike à l'étape 4 : -1169.441
## loglike à l'étape 5 : -1167.761
## loglike à l'étape 6 : -1166.026
## loglike à l'étape 7 : -1164.245
## loglike à l'étape 8 : -1162.517
## loglike à l'étape 9 : -1160.952
## loglike à l'étape 10 : -1159.637
## loglike à l'étape 11 : -1158.609
## loglike à l'étape 12 : -1157.86
## loglike à l'étape 13 : -1157.344
## loglike à l'étape 14 : -1157.004
## loglike à l'étape 15 : -1156.787
## loglike à l'étape 16 : -1156.651
## loglike à l'étape 17 : -1156.565
## loglike à l'étape 18 : -1156.512
## loglike à l'étape 19 : -1156.479
## loglike à l'étape 20 : -1156.458
## loglike à l'étape 21 : -1156.444
```

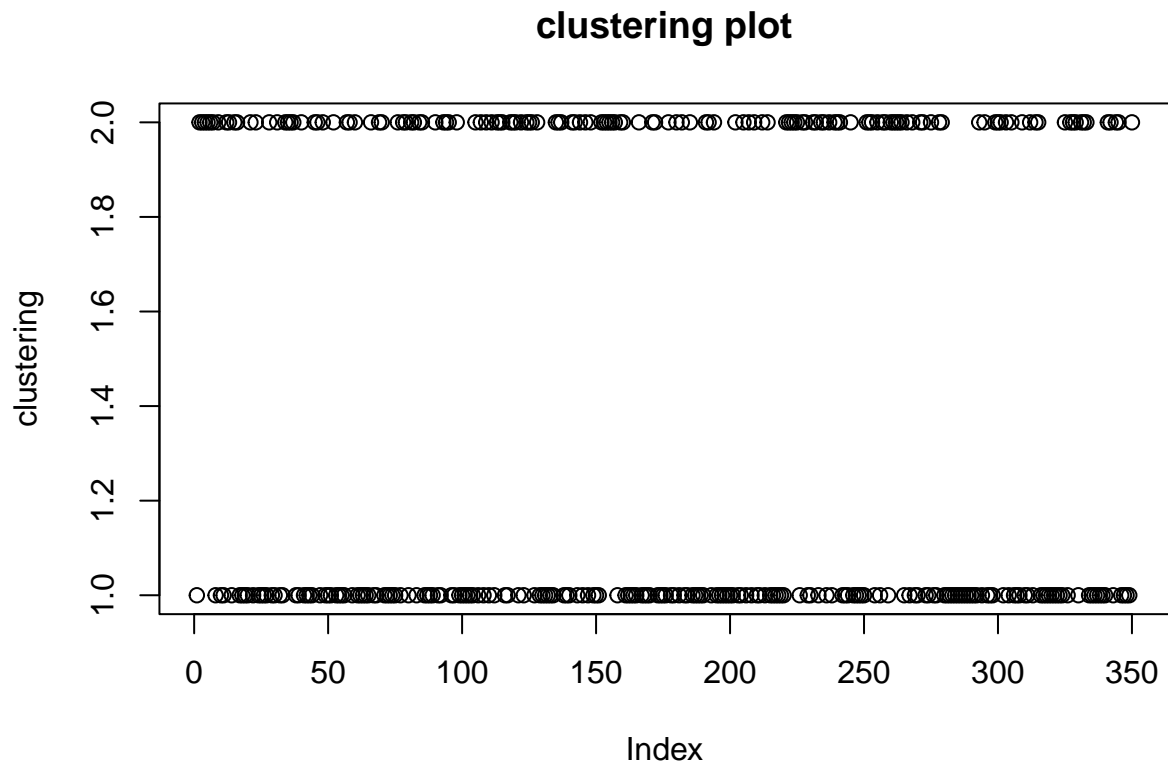


**error plot**



```
## Cluster 1
## Pi :
## [1] 0.5122733
## mu :
## [1] -1.45374
## Sigma :
## [1] 0.9064686
## Cluster 2
## Pi :
## [1] 0.4877267
## mu :
## [1] 0.3949344
## Sigma :
## [1] -0.1647762
```





On remarque que l'algorithme a convergé apres 21 étapes et que la meilleur valeur de la vraisemblance est égale à -1156.444

Les parametres estimés pour chaque cluster sont :

#cluster1:

Pi : 0.5122733

mu : -1.45374

Sigma : 0.9064686

#cluster2:

Pi estimé : 0.4877267

mu estimé : 0.3949344

Sigma estimé : -0.1647762

```
res_em
```

```
## [[1]]
```

```
## NULL
```

```
##
```

```
## [[2]]
```

```
## NULL
```

```
##
```

```
## [[3]]
```

```
##
```

```
      [,1]
```

```
      [,2]
```

```

## [1,] 8.452673e-01 0.15473270
## [2,] 1.167676e-04 0.99988323
## [3,] 6.862206e-03 0.99313779
## [4,] 2.364459e-02 0.97635541
## [5,] 3.622053e-04 0.99963779
## [6,] 3.380829e-04 0.99966192
## [7,] 1.029420e-05 0.99998971
## [8,] 7.496405e-01 0.25035953
## [9,] 5.207493e-02 0.94792507
## [10,] 9.020368e-01 0.09796321
## [11,] 8.871809e-01 0.11281914
## [12,] 1.752861e-03 0.99824714
## [13,] 4.558215e-01 0.54417848
## [14,] 6.938040e-01 0.30619595
## [15,] 4.918687e-01 0.50813129
## [16,] 9.227317e-03 0.99077268
## [17,] 9.119388e-01 0.08806116
## [18,] 7.598900e-01 0.24010996
## [19,] 7.557204e-01 0.24427958
## [20,] 5.469484e-01 0.45305164
## [21,] 4.552682e-02 0.95447318
## [22,] 5.415381e-01 0.45846188
## [23,] 1.129955e-05 0.99998870
## [24,] 9.306382e-01 0.06936185
## [25,] 9.299752e-01 0.07002477
## [26,] 8.094186e-01 0.19058143
## [27,] 7.816200e-01 0.21838004
## [28,] 6.112977e-02 0.93887023
## [29,] 8.577102e-01 0.14228976
## [30,] 5.473392e-01 0.45266080
## [31,] 4.191798e-01 0.58082015
## [32,] 8.991233e-01 0.10087672
## [33,] 9.105445e-01 0.08945547
## [34,] 8.282660e-02 0.91717340
## [35,] 1.617444e-01 0.83825559
## [36,] 1.931631e-01 0.80683694
## [37,] 4.585758e-03 0.99541424
## [38,] 7.538975e-01 0.24610247
## [39,] 7.350801e-01 0.26491986
## [40,] 2.590771e-01 0.74092285
## [41,] 8.245259e-01 0.17547408
## [42,] 8.680583e-01 0.13194170
## [43,] 5.162602e-01 0.48373984
## [44,] 8.898643e-01 0.11013570
## [45,] 7.290759e-03 0.99270924
## [46,] 7.049136e-03 0.99295086
## [47,] 8.950615e-01 0.10493852
## [48,] 4.479932e-01 0.55200683
## [49,] 8.883163e-01 0.11168375
## [50,] 8.222694e-01 0.17773065
## [51,] 8.422362e-01 0.15776377
## [52,] 4.572945e-01 0.54270553
## [53,] 8.877791e-01 0.11222087
## [54,] 8.504971e-01 0.14950294

```

```

## [55,] 8.839871e-01 0.11601286
## [56,] 8.082511e-01 0.19174889
## [57,] 1.103642e-07 0.99999989
## [58,] 4.979733e-04 0.99950203
## [59,] 8.307439e-01 0.16925605
## [60,] 9.780957e-03 0.99021904
## [61,] 9.158010e-01 0.08419905
## [62,] 7.262499e-01 0.27375015
## [63,] 7.627757e-01 0.23722429
## [64,] 6.869960e-01 0.31300401
## [65,] 5.386428e-01 0.46135721
## [66,] 4.766668e-04 0.99952333
## [67,] 8.997386e-01 0.10026136
## [68,] 8.839299e-01 0.11607012
## [69,] 4.761177e-01 0.52388232
## [70,] 3.466247e-01 0.65337531
## [71,] 8.275565e-01 0.17244346
## [72,] 8.710766e-01 0.12892340
## [73,] 9.089556e-01 0.09104436
## [74,] 5.024765e-01 0.49752352
## [75,] 8.673701e-01 0.13262994
## [76,] 3.375448e-02 0.96624552
## [77,] 8.118202e-01 0.18817984
## [78,] 4.667734e-01 0.53322655
## [79,] 2.480428e-01 0.75195723
## [80,] 7.866395e-01 0.21336045
## [81,] 1.824608e-01 0.81753917
## [82,] 1.282558e-01 0.87174416
## [83,] 8.497978e-01 0.15020224
## [84,] 4.942225e-01 0.50577753
## [85,] 2.118595e-03 0.99788140
## [86,] 5.439238e-01 0.45607619
## [87,] 6.996753e-01 0.30032474
## [88,] 8.730552e-01 0.12694483
## [89,] 8.563563e-01 0.14364366
## [90,] 1.040159e-01 0.89598410
## [91,] 9.084120e-01 0.09158804
## [92,] 5.537923e-01 0.44620774
## [93,] 5.376515e-02 0.94623485
## [94,] 1.219146e-03 0.99878085
## [95,] 2.493426e-01 0.75065741
## [96,] 8.323612e-01 0.16763885
## [97,] 9.227563e-01 0.07724368
## [98,] 8.492136e-04 0.99915079
## [99,] 9.179126e-01 0.08208741
## [100,] 7.040620e-01 0.29593803
## [101,] 8.728552e-01 0.12714476
## [102,] 9.367903e-01 0.06320971
## [103,] 8.380440e-01 0.16195600
## [104,] 9.077299e-01 0.09227010
## [105,] 1.140519e-01 0.88594807
## [106,] 6.070968e-01 0.39290325
## [107,] 1.879795e-03 0.99812020
## [108,] 5.494964e-01 0.45050363

```

## [109,] 1.326604e-01 0.86733963  
## [110,] 5.981458e-01 0.40185418  
## [111,] 3.969138e-01 0.60308618  
## [112,] 7.630340e-01 0.23696602  
## [113,] 1.916642e-01 0.80833577  
## [114,] 6.705513e-04 0.99932945  
## [115,] 6.127970e-03 0.99387203  
## [116,] 7.503045e-01 0.24969555  
## [117,] 7.870779e-01 0.21292213  
## [118,] 3.751801e-02 0.96248199  
## [119,] 4.826245e-04 0.99951738  
## [120,] 9.865376e-05 0.99990135  
## [121,] 9.258021e-01 0.07419790  
## [122,] 2.521932e-01 0.74780682  
## [123,] 9.212855e-01 0.07871455  
## [124,] 2.838328e-01 0.71616722  
## [125,] 8.948762e-02 0.91051238  
## [126,] 1.671302e-02 0.98328698  
## [127,] 5.641267e-01 0.43587325  
## [128,] 4.935132e-01 0.50648677  
## [129,] 8.932792e-01 0.10672076  
## [130,] 7.691603e-01 0.23083970  
## [131,] 7.881234e-01 0.21187658  
## [132,] 8.528569e-01 0.14714309  
## [133,] 8.228386e-01 0.17716135  
## [134,] 9.296095e-01 0.07039052  
## [135,] 1.495175e-01 0.85048246  
## [136,] 3.010478e-01 0.69895216  
## [137,] 8.772924e-02 0.91227076  
## [138,] 8.950043e-01 0.10499565  
## [139,] 8.319105e-01 0.16808946  
## [140,] 5.954374e-01 0.40456258  
## [141,] 2.181378e-01 0.78186219  
## [142,] 4.498028e-02 0.95501972  
## [143,] 5.985406e-01 0.40145944  
## [144,] 4.453874e-01 0.55461256  
## [145,] 8.919260e-01 0.10807401  
## [146,] 4.290108e-01 0.57098923  
## [147,] 7.614897e-01 0.23851029  
## [148,] 4.263466e-02 0.95736534  
## [149,] 8.217290e-01 0.17827099  
## [150,] 8.729214e-01 0.12707861  
## [151,] 6.679135e-01 0.33208650  
## [152,] 8.383150e-03 0.99161685  
## [153,] 6.283902e-03 0.99371610  
## [154,] 1.088072e-02 0.98911928  
## [155,] 6.813771e-05 0.99993186  
## [156,] 1.330368e-04 0.99986696  
## [157,] 3.791704e-01 0.62082957  
## [158,] 5.039092e-01 0.49609080  
## [159,] 2.606973e-04 0.99973930  
## [160,] 1.439471e-01 0.85605290  
## [161,] 8.131300e-01 0.18686998  
## [162,] 6.641593e-01 0.33584071

```

## [163,] 7.435479e-01 0.25645207
## [164,] 6.536802e-01 0.34631980
## [165,] 8.744965e-01 0.12550351
## [166,] 1.559998e-02 0.98440002
## [167,] 7.832645e-01 0.21673554
## [168,] 9.432357e-01 0.05676431
## [169,] 8.835984e-01 0.11640164
## [170,] 8.781497e-01 0.12185034
## [171,] 4.563841e-02 0.95436159
## [172,] 2.212613e-02 0.97787387
## [173,] 8.591686e-01 0.14083136
## [174,] 9.275826e-01 0.07241741
## [175,] 8.068903e-01 0.19310974
## [176,] 8.443728e-01 0.15562719
## [177,] 2.620116e-04 0.99973799
## [178,] 9.197289e-01 0.08027110
## [179,] 9.109783e-01 0.08902167
## [180,] 2.902209e-01 0.70977909
## [181,] 9.055280e-01 0.09447199
## [182,] 1.839582e-04 0.99981604
## [183,] 8.269447e-01 0.17305526
## [184,] 9.050539e-01 0.09494611
## [185,] 3.129285e-03 0.99687072
## [186,] 6.426905e-01 0.35730948
## [187,] 6.083958e-01 0.39160423
## [188,] 7.686469e-01 0.23135309
## [189,] 7.284082e-01 0.27159181
## [190,] 7.686337e-01 0.23136633
## [191,] 1.486959e-03 0.99851304
## [192,] 2.575580e-03 0.99742442
## [193,] 6.311307e-01 0.36886932
## [194,] 8.412925e-03 0.99158708
## [195,] 8.992545e-01 0.10074552
## [196,] 9.190813e-01 0.08091869
## [197,] 9.320704e-01 0.06792955
## [198,] 8.728849e-01 0.12711514
## [199,] 8.209691e-01 0.17903088
## [200,] 7.364219e-01 0.26357811
## [201,] 7.716832e-01 0.22831685
## [202,] 6.370127e-04 0.99936299
## [203,] 9.310273e-01 0.06897271
## [204,] 6.434968e-01 0.35650319
## [205,] 3.078364e-06 0.99999692
## [206,] 5.441128e-01 0.45588719
## [207,] 3.887150e-05 0.99996113
## [208,] 7.418044e-01 0.25819556
## [209,] 2.793310e-05 0.99997207
## [210,] 8.903729e-01 0.10962706
## [211,] 5.910579e-01 0.40894206
## [212,] 1.088337e-01 0.89116635
## [213,] 5.074071e-01 0.49259287
## [214,] 7.322526e-04 0.99926775
## [215,] 9.072191e-01 0.09278085
## [216,] 7.974329e-01 0.20256707

```

## [217,] 9.109503e-01 0.08904975  
## [218,] 6.327055e-01 0.36729454  
## [219,] 7.162864e-01 0.28371358  
## [220,] 8.207788e-01 0.17922120  
## [221,] 1.779783e-02 0.98220217  
## [222,] 1.057114e-06 0.99999894  
## [223,] 3.012997e-01 0.69870031  
## [224,] 2.693798e-01 0.73062016  
## [225,] 1.627281e-01 0.83727185  
## [226,] 8.745260e-01 0.12547397  
## [227,] 3.105432e-01 0.68945684  
## [228,] 9.575573e-02 0.90424427  
## [229,] 8.890343e-01 0.11096569  
## [230,] 9.294929e-01 0.07050714  
## [231,] 1.545276e-01 0.84547240  
## [232,] 9.456476e-02 0.90543524  
## [233,] 9.017513e-01 0.09824870  
## [234,] 2.750210e-04 0.99972498  
## [235,] 7.026568e-02 0.92973432  
## [236,] 8.194219e-01 0.18057807  
## [237,] 7.367397e-05 0.99992633  
## [238,] 8.098776e-01 0.19012243  
## [239,] 4.844341e-01 0.51556586  
## [240,] 5.794204e-03 0.99420580  
## [241,] 8.848273e-03 0.99115173  
## [242,] 9.066227e-01 0.09337732  
## [243,] 6.931918e-01 0.30680825  
## [244,] 5.398683e-01 0.46013166  
## [245,] 1.040165e-02 0.98959835  
## [246,] 9.199997e-01 0.08000029  
## [247,] 5.106819e-01 0.48931806  
## [248,] 9.122627e-01 0.08773725  
## [249,] 8.349542e-01 0.16504576  
## [250,] 9.203077e-01 0.07969229  
## [251,] 9.886378e-02 0.90113622  
## [252,] 4.717691e-04 0.99952823  
## [253,] 3.933922e-01 0.60660780  
## [254,] 5.695681e-01 0.43043190  
## [255,] 4.712762e-01 0.52872382  
## [256,] 8.811828e-01 0.11881716  
## [257,] 5.095757e-10 1.00000000  
## [258,] 3.256470e-01 0.67435300  
## [259,] 9.093094e-01 0.09069063  
## [260,] 4.045859e-01 0.59541409  
## [261,] 7.459629e-02 0.92540371  
## [262,] 2.207269e-02 0.97792731  
## [263,] 1.238114e-04 0.99987619  
## [264,] 4.108708e-02 0.95891292  
## [265,] 7.592809e-01 0.24071909  
## [266,] 2.166692e-01 0.78333076  
## [267,] 8.068520e-01 0.19314803  
## [268,] 6.685874e-04 0.99933141  
## [269,] 8.150279e-01 0.18497212  
## [270,] 9.308557e-01 0.06914428


## [271,] 4.674126e-01 0.53258744  
## [272,] 4.210378e-04 0.99957896  
## [273,] 9.259629e-01 0.07403713  
## [274,] 7.185693e-01 0.28143070  
## [275,] 1.562223e-06 0.99999844  
## [276,] 8.378825e-01 0.16211748  
## [277,] 8.730734e-01 0.12692661  
## [278,] 2.670115e-02 0.97329885  
## [279,] 4.693884e-01 0.53061165  
## [280,] 6.028301e-01 0.39716994  
## [281,] 8.940782e-01 0.10592181  
## [282,] 6.998572e-01 0.30014277  
## [283,] 7.304841e-01 0.26951588  
## [284,] 8.773259e-01 0.12267414  
## [285,] 8.830583e-01 0.11694170  
## [286,] 6.130460e-01 0.38695397  
## [287,] 7.963577e-01 0.20364229  
## [288,] 7.660119e-01 0.23398807  
## [289,] 8.710637e-01 0.12893633  
## [290,] 7.697544e-01 0.23024557  
## [291,] 8.840160e-01 0.11598397  
## [292,] 7.965364e-01 0.20346358  
## [293,] 8.307209e-03 0.99169279  
## [294,] 8.189247e-01 0.18107533  
## [295,] 2.069087e-01 0.79309127  
## [296,] 7.169559e-01 0.28304407  
## [297,] 9.343806e-01 0.06561945  
## [298,] 8.976677e-01 0.10233233  
## [299,] 5.810384e-03 0.99418962  
## [300,] 6.260606e-02 0.93739394  
## [301,] 7.304477e-03 0.99269552  
## [302,] 5.887785e-01 0.41122145  
## [303,] 2.222949e-04 0.99977771  
## [304,] 9.069553e-01 0.09304468  
## [305,] 4.459181e-01 0.55408188  
## [306,] 8.911286e-01 0.10887139  
## [307,] 6.022328e-01 0.39776720  
## [308,] 8.767467e-01 0.12325326  
## [309,] 7.889057e-02 0.92110943  
## [310,] 6.496354e-01 0.35036458  
## [311,] 6.505233e-01 0.34947668  
## [312,] 2.307534e-02 0.97692466  
## [313,] 6.386312e-01 0.36136879  
## [314,] 1.415002e-07 0.99999986  
## [315,] 3.241719e-06 0.99999676  
## [316,] 8.423579e-01 0.15764215  
## [317,] 7.172942e-01 0.28270585  
## [318,] 8.651227e-01 0.13487728  
## [319,] 8.053887e-01 0.19461132  
## [320,] 8.228091e-01 0.17719090  
## [321,] 8.817867e-01 0.11821330  
## [322,] 7.835878e-01 0.21641218  
## [323,] 8.573623e-01 0.14263770  
## [324,] 6.215655e-01 0.37843452

```

## [325,] 8.514677e-03 0.99148532
## [326,] 8.295673e-01 0.17043270
## [327,] 1.047573e-01 0.89524267
## [328,] 9.114954e-03 0.99088505
## [329,] 2.289794e-04 0.99977102
## [330,] 8.086375e-01 0.19136246
## [331,] 3.286688e-02 0.96713312
## [332,] 7.071091e-04 0.99929289
## [333,] 3.562987e-01 0.64370135
## [334,] 7.979868e-01 0.20201320
## [335,] 7.340717e-01 0.26592833
## [336,] 8.624337e-01 0.13756628
## [337,] 7.450273e-01 0.25497270
## [338,] 5.564919e-01 0.44350809
## [339,] 8.731116e-01 0.12688836
## [340,] 7.854930e-01 0.21450696
## [341,] 6.252023e-03 0.99374798
## [342,] 3.511369e-01 0.64886306
## [343,] 9.085369e-01 0.09146309
## [344,] 3.379459e-04 0.99966205
## [345,] 4.558573e-04 0.99954414
## [346,] 6.854344e-01 0.31456560
## [347,] 8.862438e-01 0.11375623
## [348,] 7.778825e-01 0.22211753
## [349,] 9.123170e-01 0.08768301
## [350,] 1.018101e-04 0.99989819
##
## [[4]]
## [1] 1 2 2 2 2 2 2 1 2 1 1 2 2 1 2 2 1 1 1 2 1 2 1 1 1 2 1 1 2 1 1 2 2 2 2
## [38] 1 1 2 1 1 1 1 2 2 1 2 1 1 1 2 1 1 1 1 2 2 1 2 1 1 1 1 1 2 1 1 2 2 1 1 1 1
## [75] 1 2 1 2 2 1 2 2 1 2 2 1 1 1 1 2 1 1 2 2 2 1 1 2 1 1 1 1 1 1 2 1 2 1 2 1 2
## [112] 1 2 2 2 1 1 2 2 2 1 2 1 2 2 2 1 2 1 1 1 1 1 2 2 2 1 1 1 2 2 1 2 1 2 1 2
## [149] 1 1 1 2 2 2 2 2 2 1 2 2 1 1 1 1 1 2 1 1 1 1 2 2 1 1 1 1 2 1 1 2 1 2 1 1 2
## [186] 1 1 1 1 1 2 2 1 2 1 1 1 1 1 1 1 2 1 1 2 1 2 1 2 1 1 2 1 2 1 1 1 1 1 1 2 2
## [223] 2 2 2 1 2 2 1 1 2 2 1 2 2 1 2 1 2 2 2 1 1 1 2 1 1 1 1 1 2 2 2 1 2 1 2 2 1
## [260] 2 2 2 2 2 1 2 1 2 1 1 2 2 1 1 2 1 1 2 2 1 1 1 1 1 1 1 1 1 1 1 1 1 1 2 1 2 1
## [297] 1 1 2 2 2 1 2 1 2 1 1 1 2 1 1 2 1 2 2 1 1 1 1 1 1 1 1 1 1 2 1 2 2 2 1 2 2 2
## [334] 1 1 1 1 1 1 1 2 2 1 2 2 1 1 1 1 2
##
## [[5]]
## NULL
##
## [[6]]

```





On remarque ici que la probabilité que le premier point appartienne au premier cluster est plus grande que la probabilité d'appartenance au second cluster


On voit bien que le premier point appartient au premier cluster

Les données sont bien regroupées en deux clusters selon le plot final

*Deuxième expérience: appliquer EM sur les données Iris*

#charger les données:

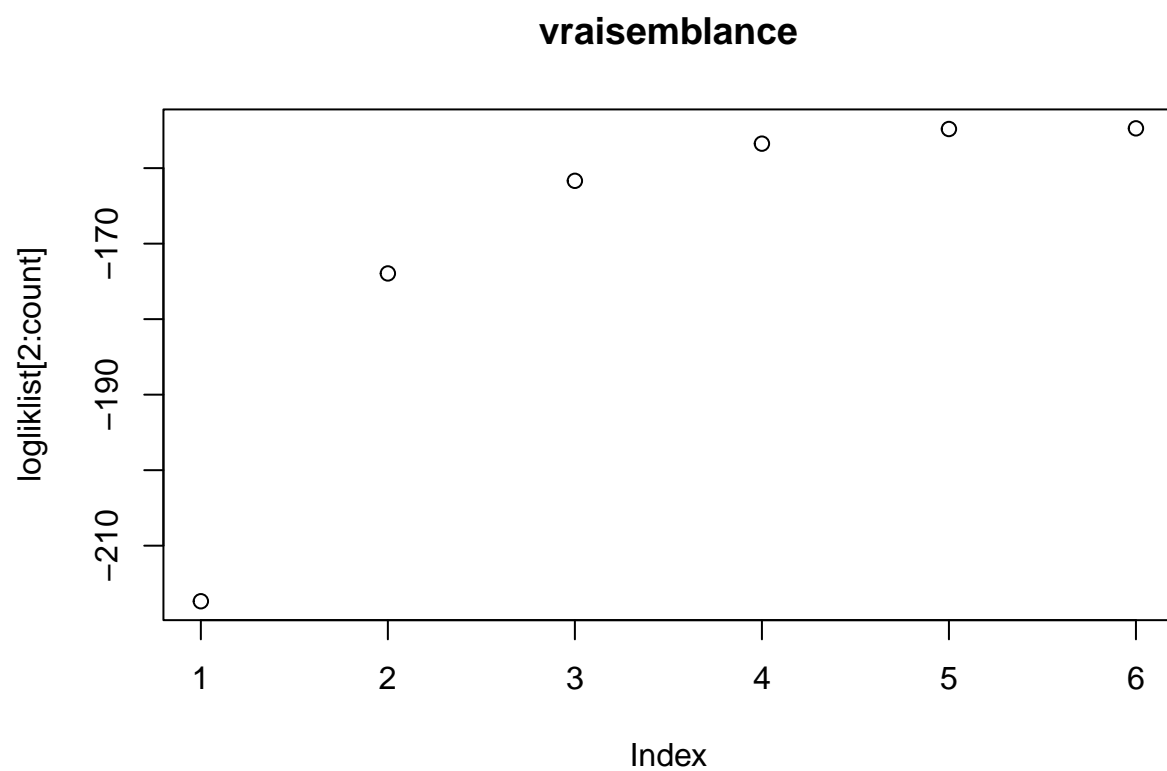
```
data_iris<-as.matrix(iris[,3:4])
plot(data_iris)
```




```
set.seed(1010)
```

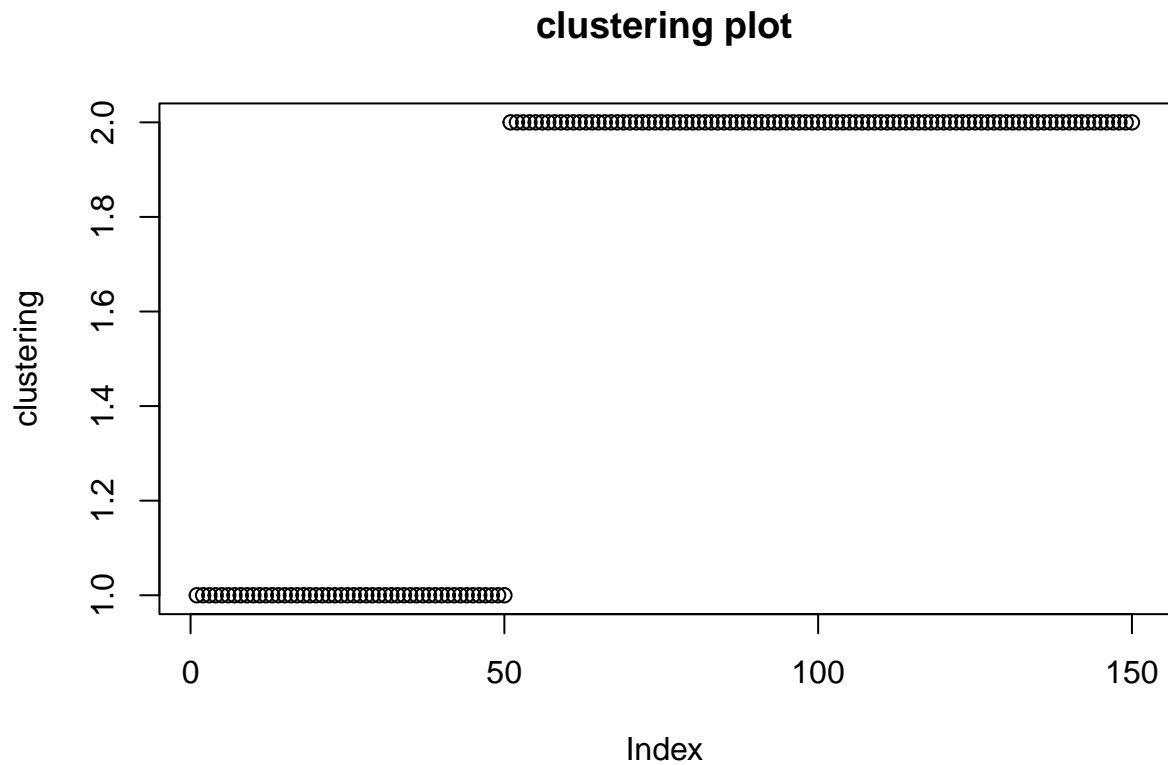
```
K<-2 #nombre de clusters
degree <- 2 #degre de données(2D)
N <- 150 #nombre de samples
n.trial<-150
e<-1e-5
res_em = EM(data_iris,K,n.trial,e)
```

```
## loglike à l'étape 1 : -217.3579
## loglike à l'étape 2 : -173.9462
## loglike à l'étape 3 : -161.6819
## loglike à l'étape 4 : -156.7562
## loglike à l'étape 5 : -154.8197
## loglike à l'étape 6 : -154.7315
```





```
## Cluster 1
## Pi :
## [1] 0.3331373
## mu :
## [1] 1.461816
## Sigma :
## [1] 0.0295005
## Cluster 2
## Pi :
## [1] 0.6668627
## mu :
## [1] 0.2459251
## Sigma :
## [1] 0.005936244
```



On voit que l'algorithme converge apres 6 étapes avec une meilleur vraisemblance de -154.7315

Les parametres estimés pour chaque cluster sont :

#cluster1:

pi estimé : 0.3331373

mu estimé : 1.461816

Sigma estimé: 0.0295005

#Cluster2:

Pi estimé : 0.6668627

mu estimé : 0.2459251

Sigma estimé : 0.005936244

```
res_em
```

```
## [[1]]
## NULL
##
## [[2]]
## NULL
##
## [[3]]
##          [,1]      [,2]
## [1,] 9.999772e-01 2.278703e-05
```

```

## [2,] 9.999772e-01 2.278703e-05
## [3,] 9.999816e-01 1.837453e-05
## [4,] 9.999605e-01 3.950937e-05
## [5,] 9.999772e-01 2.278703e-05
## [6,] 9.996063e-01 3.936846e-04
## [7,] 9.999756e-01 2.442551e-05
## [8,] 9.999605e-01 3.950937e-05
## [9,] 9.999772e-01 2.278703e-05
## [10,] 9.999002e-01 9.983710e-05
## [11,] 9.999605e-01 3.950937e-05
## [12,] 9.999042e-01 9.577267e-05
## [13,] 9.999497e-01 5.033173e-05
## [14,] 9.999518e-01 4.816208e-05
## [15,] 9.999793e-01 2.071514e-05
## [16,] 9.999179e-01 8.211331e-05
## [17,] 9.999346e-01 6.542375e-05
## [18,] 9.999756e-01 2.442551e-05
## [19,] 9.997677e-01 2.323246e-04
## [20,] 9.999630e-01 3.701740e-05
## [21,] 9.996755e-01 3.245296e-04
## [22,] 9.999179e-01 8.211331e-05
## [23,] 9.999280e-01 7.195316e-05
## [24,] 9.984221e-01 1.577901e-03
## [25,] 9.899109e-01 1.008914e-02
## [26,] 9.999042e-01 9.577267e-05
## [27,] 9.998479e-01 1.520706e-04
## [28,] 9.999605e-01 3.950937e-05
## [29,] 9.999772e-01 2.278703e-05
## [30,] 9.999042e-01 9.577267e-05
## [31,] 9.999042e-01 9.577267e-05
## [32,] 9.999179e-01 8.211331e-05
## [33,] 9.999002e-01 9.983710e-05
## [34,] 9.999772e-01 2.278703e-05
## [35,] 9.999605e-01 3.950937e-05
## [36,] 9.999793e-01 2.071514e-05
## [37,] 9.999816e-01 1.837453e-05
## [38,] 9.999497e-01 5.033173e-05
## [39,] 9.999816e-01 1.837453e-05
## [40,] 9.999605e-01 3.950937e-05
## [41,] 9.999775e-01 2.253320e-05
## [42,] 9.999775e-01 2.253320e-05
## [43,] 9.999816e-01 1.837453e-05
## [44,] 9.924674e-01 7.532621e-03
## [45,] 9.928344e-01 7.165581e-03
## [46,] 9.999756e-01 2.442551e-05
## [47,] 9.999042e-01 9.577267e-05
## [48,] 9.999772e-01 2.278703e-05
## [49,] 9.999605e-01 3.950937e-05
## [50,] 9.999772e-01 2.278703e-05
## [51,] 9.683745e-83 1.000000e+00
## [52,] 3.316115e-77 1.000000e+00
## [53,] 4.819959e-94 1.000000e+00
## [54,] 8.376372e-54 1.000000e+00
## [55,] 3.384951e-81 1.000000e+00

```


```

## [56,] 3.684204e-72 1.000000e+00
## [57,] 2.663740e-88 1.000000e+00
## [58,] 2.371008e-27 1.000000e+00
## [59,] 2.873178e-76 1.000000e+00
## [60,] 2.960414e-53 1.000000e+00
## [61,] 1.431601e-32 1.000000e+00
## [62,] 4.174304e-66 1.000000e+00
## [63,] 3.639035e-48 1.000000e+00
## [64,] 9.683745e-83 1.000000e+00
## [65,] 9.740784e-42 1.000000e+00
## [66,] 1.363424e-70 1.000000e+00
## [67,] 3.316115e-77 1.000000e+00
## [68,] 1.012466e-51 1.000000e+00
## [69,] 3.316115e-77 1.000000e+00
## [70,] 2.556268e-46 1.000000e+00
## [71,] 1.823206e-99 1.000000e+00
## [72,] 8.376372e-54 1.000000e+00
## [73,] 4.819959e-94 1.000000e+00
## [74,] 1.120223e-78 1.000000e+00
## [75,] 2.216497e-64 1.000000e+00
## [76,] 1.363424e-70 1.000000e+00
## [77,] 4.419995e-87 1.000000e+00
## [78,] 1.416759e-104 1.000000e+00
## [79,] 3.316115e-77 1.000000e+00
## [80,] 1.431601e-32 1.000000e+00
## [81,] 4.108354e-43 1.000000e+00
## [82,] 2.262176e-38 1.000000e+00
## [83,] 2.950152e-48 1.000000e+00
## [84,] 4.543008e-106 1.000000e+00
## [85,] 3.316115e-77 1.000000e+00
## [86,] 2.730792e-80 1.000000e+00
## [87,] 2.471319e-85 1.000000e+00
## [88,] 3.378925e-68 1.000000e+00
## [89,] 3.489843e-57 1.000000e+00
## [90,] 8.376372e-54 1.000000e+00
## [91,] 3.536743e-66 1.000000e+00
## [92,] 1.517465e-78 1.000000e+00
## [93,] 1.502065e-51 1.000000e+00
## [94,] 2.371008e-27 1.000000e+00
## [95,] 1.039943e-60 1.000000e+00
## [96,] 1.424750e-58 1.000000e+00
## [97,] 1.039943e-60 1.000000e+00
## [98,] 2.216497e-64 1.000000e+00
## [99,] 1.053164e-22 1.000000e+00
## [100,] 3.489843e-57 1.000000e+00
## [101,] 2.831259e-191 1.000000e+00
## [102,] 1.623751e-116 1.000000e+00
## [103,] 1.548529e-165 1.000000e+00
## [104,] 1.467780e-137 1.000000e+00
## [105,] 1.419006e-164 1.000000e+00
## [106,] 2.439833e-208 1.000000e+00
## [107,] 9.497844e-84 1.000000e+00
## [108,] 1.559846e-178 1.000000e+00
## [109,] 1.540477e-148 1.000000e+00

```

[illegible]





On remarque ici que la probabilité que le premier point appartient au premier cluster est  $9.999772e-01$ , et pour le second cluster est  $2.278703e-05$

On voit bien que le premier point appartient au premier cluster!

Les données sont bien regroupées en deux clusters finalement.